

# Tarea 5 Reconocimiento de Patrones

Yamil Ernesto Morfa

17 de marzo de 2021

## B. Preguntas cortas

1. Tomamos el primer ejemplo del algoritmo MM, ver Recpat12n.pdf.

$$h_i(\theta | \theta^n) = 0,5 \frac{(y_i - \theta)^2}{|y_i - \theta^n|} + 0,5 |y_i - \theta^n|$$

$$f_i(\theta) = |y_i - \theta|$$

decimos que una función  $g(\theta | \theta^n)$  mayoriza a  $f(\theta)$  en  $\theta^n$  si se cumple que:

$$\begin{aligned} f(\theta^n) &= g(\theta^n | \theta^n) \\ f(\theta) &\leq g(\theta | \theta^n) \quad \forall \theta \end{aligned}$$

Entonces tenemos que:

$$h_i(\theta^n | \theta^n) = 0,5 \frac{(y_i - \theta^n)^2}{|y_i - \theta^n|} + 0,5 |y_i - \theta^n| = (0,5 + 0,5) |y_i - \theta^n| = |y_i - \theta^n| = f(\theta^n)$$

$$h_i(\theta | \theta^n) = 0,5 \frac{(y_i - \theta)^2}{|y_i - \theta^n|} + 0,5 |y_i - \theta^n| = \frac{1}{|y_i - \theta^n|} \left\{ \frac{(y_i - \theta)^2 + |y_i - \theta^n|^2}{2} \right\} \geq \frac{1}{|y_i - \theta^n|} \left\{ \sqrt{(y_i - \theta)^2 |y_i - \theta^n|^2} \right\} = *$$

pues por la Desigualdad de las medias aritmética y geométrica nos dice que  $\frac{a+b}{2} \geq \sqrt{ab}$

$$* = \sqrt{(y_i - \theta)^2} = |y_i - \theta| = f(\theta)$$

luego  $h_i(\theta | \theta^n) \geq f(\theta) \quad \forall \theta$ .

2. La desigualdad de Jensen establece que: Sean  $f, g : \mathbb{R} \rightarrow \mathbb{R}$  con  $f$  convexa, entonces  $E[f(g(X))] \geq f(E[g(X)])$ . Ahora supongamos  $X \sim P^1$  y  $Y = g(X) = \frac{P^2(X)}{P^1(X)}$ , sea  $f(x) = -\log(x)$  (convexa), entonces por la desigualdad de Jensen tenemos:

$$E_X[f(g(X))] \geq f(E_X[g(X)]) \implies \begin{cases} \sum_i P^1(x_i) f(g(x_i)) \geq f(\sum_i P^1(x_i) g(x_i)) & \text{caso discreto} \\ \int P^1(x) f(g(x)) dx \geq f(\int P^1(x) g(x) dx) & \text{caso continuo} \end{cases}$$

$$\begin{aligned} &\Rightarrow \begin{cases} -\sum_i P^1(x_i) \log\left(\frac{P^2(x_i)}{P^1(x_i)}\right) \geq -\log\left(\sum_i P^1(x_i) \frac{P^2(x_i)}{P^1(x_i)}\right) \\ -\int P^1(x) \log\left(\frac{P^2(x)}{P^1(x)}\right) dx \geq -\log\left(\int P^1(x) \frac{P^2(x)}{P^1(x)} dx\right) \end{cases} \\ &\Rightarrow \begin{cases} \sum_i P^1(x_i) \log\left(\frac{P^1(x_i)}{P^2(x_i)}\right) \geq -\log\left(\sum_i P^2(x_i)\right) = -\log 1 = 0 \\ \int P^1(x) \log\left(\frac{P^1(x)}{P^2(x)}\right) dx \geq -\log\left(\int P^2(x) dx\right) = -\log 1 = 0 \end{cases} \Rightarrow d(P^1, P^2) \geq 0 \end{aligned}$$

## C. Análisis de datos

- Supongamos que tenemos un conjunto de datos  $D = \{x_1, \dots, x_N\}$  donde  $x_i$  es un vector de dimensión  $d$ . Supongamos además que estos son generados de manera aleatoria y *i.i.d* por una densidad  $p(x|\theta)$  definida como la mezcla finita de  $K$  densidades.

$$p(x|\theta) = \sum_{k=1}^K \alpha_k p_k(x|z_k, \theta_k)$$

con  $z = (z_1, \dots, z_K)$  con  $z_k = \begin{cases} 0 \\ 1 \end{cases}$  y  $\sum_{k=1}^K z_k = 1$ ,  $\alpha_k = p_k(z_k)$  son los pesos de la mezcla, que representan que una variable  $x$  seleccionada aleatoriamente fue generada por la componente  $k$ ,  $\sum_{k=1}^K \alpha_k = 1$ . El conjunto de parámetros de una modelo de  $K$  mezclas es

$$\theta = \{\alpha_1, \dots, \alpha_K, \theta_1, \dots, \theta_K\}$$

Podemos calcular

$$w_{ik} = p(z_{ik} = 1 | x_i, \theta) = \frac{\alpha_k p_k(x_i | z_k, \theta_k)}{\sum_{m=1}^K \alpha_m p_m(x_i | z_m, \theta_m)}, \quad 1 \leq k \leq K, \quad 1 \leq i \leq N$$

Si asumimos que las densidades  $p_k$  son Gaussianas para cada componente con parámetros  $\theta_k = \{\mu_k, \Sigma_k\}$

$$p_k(x | \mu_k, \Sigma_k) = \frac{1}{(2\pi)^{d/2} |\Sigma_k|^{1/2}} \exp\left\{-\frac{1}{2} (x - \mu_k)^T \Sigma_k^{-1} (x - \mu_k)\right\}$$

El algoritmo EM es un algoritmo iterativo que comienza con una estimación aleatoria inicial de los parámetros  $\theta$  y luego actualiza dichos parámetros hasta convergencia. Cada iteración consiste de dos pasos:

**E-Step:** Dado los valores actuales de  $\theta$  calculamos  $W$  la matriz de pesos de  $N \times K$  conformada por los valores  $\{W\}_{ik} = w_{ik}$

**M-Step:** Utilizamos los pesos obtenidos para calcular los nuevos parámetros. Sea  $N_k = \sum_{i=1}^N w_{ik}$  entonces:

$$\alpha_k^{new} = \frac{N_k}{N}$$

$$\mu_k^{new} = \left(\frac{1}{N_k}\right) \sum_{i=1}^N w_{ik} x_i$$

$$\Sigma_k^{new} = \left(\frac{1}{N_k}\right) \sum_{i=1}^N w_{ik} (x_i - \mu_k^{new})(x_i - \mu_k^{new})^T$$


### Convergencia:

La convergencia generalmente se detecta calculando el valor de la logverosimilitud después de cada iteración y deteniéndose cuando parece que no cambia de manera significativa de una iteración a la siguiente.

### Ejemplo\_1:


Para este ejemplo se toman datos de 3 normales bivariadas con  $\mu_1 = (-5, -5)$ ,  $\mu_2 = (0, 0)$ ,  $\mu_3 = (5, 5)$  y  $\Sigma_1 = \Sigma_2 = \Sigma_3 = 0,5I$  como se muestran en la figura 1

Figura 1:



Como podemos ver este es un ejemplo en donde los grupos están muy bien separados. En consecuencia el algoritmo *EM* devuelve buenos resultados, sin embargo *K - means* tiene problemas para agrupar bien estos datos. Esto se muestra en la Fig 2


Figura 2:



### Ejemplo\_2:

Se Tomaron las normales bivariadas del ejemplo anterior solo que esta vez tomando  $\Sigma_1 = \Sigma_2 = \Sigma_3 = 2,5I$ . Los resultados obtenidos se muestran en la figura 3

Figura 3:



A pesar del buen comportamiento mostrado, EM tiene varios problemas en relación a la inicialización y a la convergencia.